

海南大学

课程论文

基于 PPG+EDA 多模态信号的 轻量级可穿戴情感状态检测系统

课程名称: 劳动教育实践 4——专业劳动实践

选题方向: 多模态生理信号分析

学 号: 20243002066

姓 名: 周增飏

提交日期: 2026 年 7 月 15 日

摘要

心理健康与压力的客观连续监测是可穿戴健康领域的重要需求。本文面向资源约束场景，设计参数量仅 21,627 的轻量级双分支 1D-CNN，联合手腕 PPG（64 Hz）与 EDA（4 Hz）信号，实现基线/压力/娱乐三分类情感检测。使用 WESAD 数据集（15 名被试），严格采用留一被试交叉验证（LOSO）。预处理含 Chebyshev 带通滤波、per-subject Z-score 标准化、80% 标签纯净度过滤与信号质量评估。结果表明：特征级融合取得 74.9% 准确率与 71.0% 宏 F1；消融实验证实融合显著优于 PPG 单模态（Wilcoxon $p=0.001$ ）；EDA 单模态判别力反强于 PPG，且以仅 3,115 参数达 66.8% 准确率。本文附带 React 可交互前端验证系统。

关键词：可穿戴计算；情感状态检测；多模态融合；一维卷积神经网络；WESAD；留一被试交叉验证

目 录

一、引言	1
1.1 研究背景	1
1.2 研究动机与挑战	1
1.3 研究内容与贡献	1
二、数据来源与实验方法	2
2.1 WESAD 数据集	2
2.2 三分类任务与类别分布	3
2.3 LOSO 留一被试交叉验证	3
三、数据预处理	3
四、数据分析与特征提取	5
4.1 时域分析与 HRV	6
4.2 频域分析	6
4.3 时频分析	7
4.4 HRV 特征统计与深度自动特征	7
五、深度学习模型设计	8
5.1 不对称双分支架构	8
5.2 特征级融合与分类	9
5.3 训练设置	9
六、可视化结果	9
6.1 前端可视化验证系统	11
七、分析与讨论	11
7.1 整体性能与混淆模式	11
7.2 关于 H1 的诚实讨论	12
7.3 关于 H2：融合策略消融	13
7.4 EDA 单模态反强于 PPG 的发现	14
7.5 局限性与未来工作	14
八、结论	14
九、参考文献	15
附录：代码说明	16

一、引言

1.1 研究背景

心理健康问题已成为全球性公共卫生挑战。世界卫生组织数据显示，全球约 10 亿人受到精神健康问题影响，而专业心理健康服务在资源有限地区供给严重不足。传统压力与情绪评估依赖主观问卷量表（如 PSS-10、STAI），存在即时性差、回溯偏差、无法连续监测等固有局限。随着可穿戴设备的普及，通过日常佩戴的智能手表、手环持续采集生理信号，实现压力与情感状态的客观、连续、无创监测，正成为一种新的可能。

可穿戴设备内置的光电容积脉搏波（PPG）传感器通过测量血容积变化，可间接提取心率与心率变异性（HRV）等心血管指标；皮肤电活动（EDA）传感器通过测量皮肤电导率反映交感神经系统的激活程度，是情感唤醒与认知负荷的敏感指标。两者组合为情感状态推断提供了互补的信息维度：PPG 主要反映心血管系统的自主神经调控，EDA 则直接映射交感神经兴奋程度。

1.2 研究动机与挑战

面向可穿戴实际部署的多模态情感计算仍面临三个挑战。其一，计算资源约束与模型复杂度的矛盾：现有研究多采用深层网络或复杂特征工程，参数量动辄数百万，难以部署到资源受限的腕戴设备。其二，个体差异导致泛化能力不足：许多研究采用随机划分，将同一被试数据同时用于训练和测试，导致对跨被试泛化能力的高估。其三，多模态融合策略的有效性有待系统验证：PPG 与 EDA 在采样率、信号形态、物理含义上差异显著，何种融合策略最优仍是开放问题。

1.3 研究内容与贡献

本文围绕“面向可穿戴资源约束的轻量级多模态情感检测”展开，主要贡献包括：

轻量级不对称双分支架构：针对 PPG（640 点）与 EDA（40 点）信号长度差异，设计各自适配的双分支 1D-CNN，总参数量仅 21,627，远小于主流深层网络。

严格的被试独立评估：全程采用 LOSO 留一被试交叉验证，避免被试信息泄露，提供可靠的跨被试泛化基准。

系统性的融合策略消融：对比特征级融合、晚期融合与两种单模态共四种配置，并通过 Wilcoxon 符号秩检验判定显著性。

EDA 判别力优于 PPG 的独立发现：消融实验揭示 EDA 单模态在跨被试三分类中的判别力反强于 PPG，为可穿戴传感器选型提供实证依据。

前端可视化验证系统：构建医学监护仪风格的 React 可交互前端，支持被试与状态切换，展示完整数据流。

二、数据来源与实验方法

2.1 WESAD 数据集

本研究使用 WESAD（Wearable Stress and Affect Detection）公开数据集 [4]。该数据集由德国班贝格大学与奥格斯堡大学 Schmidt 等人于 2018 年在 ICMI 发布，是生理信号情感计算领域最具代表性的公开数据集之一。数据集概况见表 1。

属性	说明
被试人数	15 人（12 男 3 女，年龄 25.8±4.0 岁；编号 S2–S17，无 S12）
手腕信号（Empatica E4）	PPG(BVP) 64 Hz、EDA 4 Hz、TEMP 4 Hz、ACC 32 Hz
胸部信号（RespiBAN Pro）	ECG、EDA、EMG、RESP、TEMP、ACC，均 700 Hz
情感状态标签	基线、压力、娱乐，700 Hz 同步标注
诱导范式	基线：静息；压力：特里尔社会压力测试（TSST）；娱乐：观看幽默视频
数据格式	Python pickle (.pkl)

获取方式	官网免费下载（需签署使用协议）
------	-----------------

表 1 WESAD 数据集概况

注：原数据集编号含 S12，但因该被试数据损坏被官方弃用，故实际可用被试为 15 人。本文仅使用手腕 PPG（64 Hz）与 EDA（4 Hz）用于分类，胸部 ECG（700 Hz）用于 HRV 特征分析的金标准参照，保证研究主线与真实腕戴设备的可获得信号一致。

2.2 三分类任务与类别分布

任务为三分类：基线（label=1）、压力（label=2）、娱乐（label=3）。经预处理与分窗后（详见第三节），每名被试约得到 421–451 个 10 秒窗口，三类窗口数比例约为基线:压力:娱乐 $\approx$ 3.2:1.8:1（例如 S2 为 228:122:71）。基线为多数类、娱乐为少数类，存在明显类别不平衡，这一先验分布指导了后续的损失加权与评估指标选择。

2.3 LOSO 留一被试交叉验证

为严格评估跨被试泛化能力，本文采用 LOSO 协议：每次以 1 名被试为测试集、其余 14 名为训练集，循环 15 次，聚合全部测试预测后计算整体准确率、宏 F1、每类 Precision/Recall/F1 与混淆矩阵。该协议保证训练集与测试集无同一被试数据，反映模型对新用户的真实泛化水平。折内早期停止所用的验证集从 14 名训练被试的窗口中随机按 8:2 划分，测试被试绝不参与模型选择，杜绝被试泄露。

三、数据预处理

预处理是生理信号分析的关键环节。本文的预处理链路如下，其中若干步骤涉及直接影响泛化性能的工程决策（标注【决策】）。

（1）标签重采样与时间对齐【决策】。WESAD 标签存储于胸部设备（700 Hz），而手腕 BVP 与 EDA 分别为 64 Hz 与 4 Hz。若直接套用会导致标签错

位、性能崩盘。本文按时间映射将标签重采样到 64 Hz，保证标签与 PPG 采样点严格对齐。

(2) 带通/低通滤波。PPG 采用 Chebyshev II 型带通滤波器，通带 0.5–8 Hz，覆盖心率及其谐波所在的生理频段，同时抑制呼吸基线漂移与高频噪声；EDA 采用 1 Hz 低通滤波器，保留反映交感唤醒的慢变成分（SCL）。

(3) 工频干扰抑制。设计二阶 IIR 陷波滤波器（ $Q=35$ ）针对 50 Hz；由于 PPG 采样率为 64 Hz，该步骤在本文信号上实际不触发，但保留以适用于更高采样率场景。

(4) per-subject Z-score 标准化【决策】。每名被试利用其全记录的无标签统计量(μ, σ)对自身信号做标准化。该方案无需标签信息，且模拟了可穿戴设备以用户自身基线数据校准的实际部署场景。从信息论角度，per-subject 标准化既保留了“压力状态下 EDA 基础电导水平（SCL）相对自身均值正向偏离”这一条件信号，又去除了被试间基线噪声，最契合跨被试泛化目标。

(5) 信号分段。采用 10 秒窗口、5 秒步长（50%重叠）。PPG 窗口长度 640 点，EDA 窗口长度 40 点。

(6) 窗口标签纯净度过滤【决策】。WESAD 标签在条件切换过渡段大量为 0（undefined）。对每个 10 秒窗口取多数票标签，要求主标签占比 $\geq 80\%$ 才保留，剔除跨条件边界窗口，仅保留三类有效窗口。

(7) 信号质量评估（SQI）。采用加权融合指标 $SQI = 0.4 \times \text{波形相关性} + 0.3 \times \text{幅度合理性} + 0.3 \times \text{峰值计数合理性}$ ，其中波形相关性为窗口与理想 PPG 脉搏模板的归一化互相关最大值（模板匹配思想参考 Li 与 Clifford 的工作 [12]），幅度合理性依据窗口标准差是否落入经验区间，峰值计数合理性依据推算心率是否落在 30–180 bpm。三个分量以启发式权重加权融合，未做敏感性搜索。窗口 $SQI < 0.5$ 予以丢弃。




图 1 原始 PPG 与 EDA 波形（被试 S2，10 s）




图 2 滤波与标准化后的波形（被试 S2）

四、数据分析与特征提取

为满足多维度分析的要求，本文从时域、频域、时频域三个角度分析不同情感状态下 PPG 与 EDA 信号的差异，并据此构造可解释的手工特征；同时训练端到端的 1D-CNN 自动学习特征。

4.1 时域分析与 HRV

为保证 HRV 估计的可靠性，本文的 HRV 特征分析基于胸部 ECG（700 Hz）的 R 峰检测（Pan-Tompkins 简化算法：带通 5–15 Hz→微分平方→滑动积分→峰值精化），作为 PPG 脉搏检测的金标准参照；而分类模型仍使用手腕 PPG+EDA，保持可穿戴主线不变。之所以采用 ECG 而非 PPG 进行 HRV 分析，是因为 PPG 脉搏检测受运动伪影与重搏切迹干扰严重，实测得到的 SDNN/RMSSD 数值畸高且无法区分状态；改用 ECG 后各项指标均落入生理合理区间并能正确反映状态差异。

由 R-R 间期计算 HRV 时域指标：SDNN（全部 NN 间期标准差，反映总体心率变异性）、RMSSD（相邻 NN 间期差值的均方根，反映副交感调控）、HR_mean（平均心率）。对 EDA 计算窗口均值（近似 SCL）与标准差，反映基础电导水平与波动程度。

4.2 频域分析

对去趋势后的 PPG 序列做快速傅里叶变换（FFT），计算功率谱密度。对 R-R 间期序列重采样后做 Welch 谱估计，按生理频带积分：VLF（0.003–0.04 Hz）、LF（0.04–0.15 Hz，交感+副交感）、HF（0.15–0.4 Hz，副交感），以及 LF/HF 比值（反映自主神经平衡）。预期压力状态下 LF/HF 升高。




图 3 PPG 快速傅里叶变换功率谱密度

4.3 时频分析

采用短时傅里叶变换（STFT）绘制时频谱图，Hanning 窗、256 点窗长、192 点重叠，观察心率频率分量随时间的动态变化，直观展示不同状态下脉搏节律的稳定性。




图 4 PPG 短时傅里叶变换时频谱图（被试 S2 压力段）

4.4 HRV 特征统计与深度自动特征

将 15 名被试在 60 秒长窗下提取的 HRV 特征按状态分组统计，结果见图 5 与表 2。上述手工特征用于可视化与可解释性分析，而分类由端到端 1D-CNN 完成，模型直接以原始预处理后的双通道信号为输入，自动学习多层次特征表示。




图 5 三状态 HRV 特征箱线图（15 名被试）

特征	基线	压力	娱乐	生理预期
SDNN (ms)	59.9	46.0	63.7	压力↓
RMSSD (ms)	41.7	28.2	41.7	压力↓
LF/HF	2.1	2.6	2.9	压力↑
HR_mean (bpm)	71.3	93.3	71.6	压力↑

表 2 HRV 特征三状态中位数（15 被试，ECG，60 s 窗）

压力下 SDNN、RMSSD 降低、HR 显著升高（+22 bpm）、LF/HF 升高，符合交感占主的生理规律；娱乐组各项接近基线，印证其“轻度正向唤醒”定位。

五、深度学习模型设计

5.1 不对称双分支架构

由于 PPG（640 点）与 EDA（40 点）信号长度相差 16 倍，若共用同一套池化栈，EDA 经多次下采样将退化为长度 2 的序列、信息殆尽。为此本文设计不对称双分支结构，各自适配信号长度。

PPG 分支包含 3 个卷积块（Conv1D+ELU+BatchNorm+MaxPool(2)），通道数 32→48→64，第一层卷积核 $k=5$ （感受野约 78 ms，覆盖收缩峰上升沿），后两层 $k=3$ ；经三次池化后序列长度 640→80，全局平均池化得到 64 维特征。

EDA 分支包含 2 个卷积块，通道数 16→24，卷积核 $k=3$ （4 Hz 下 $k=3$ 对应 0.75 s，已覆盖 EDA 慢动态）；经两次池化 40→10，全局平均池化得到 24 维特征。




图 9 双分支 1D-CNN 架构示意图

5.2 特征级融合与分类

两分支输出拼接为 88 维向量，送入全连接层（88→64，ELU，Dropout 0.3）与输出层（64→3）。模型总参数量 21,627（约 2.16 万），权重文件仅约 0.083 MB，满足可穿戴设备的资源约束。

为验证融合策略有效性，本文实现四种可切换变体：**dual**（特征级融合，主模型）、**ppg**（仅 PPG）、**eda**（仅 EDA）、**late**（两分支各自分类后概率平均）。

5.3 训练设置

优化器 Adam（lr=1e-3），损失函数为类别加权交叉熵（权重=训练集各类频率倒数，缓解不平衡）。最大 60 个 epoch，patience=10 的早停（基于验证集损失）。全局随机种子固定为 42，保证可复现。

六、可视化结果

本节给出代表性被试（S2）的信号处理结果、全体 LOSO 评估结果与前端系统。所有图表均含标题、坐标轴标签、单位与图例，共 10 幅，覆盖原始波形、处理后波形、频谱、时频、统计图四类（任务书要求≥8 幅且四类齐全）。

图 1-2 展示预处理前后对照：原始 PPG 含明显基线漂移与噪声，EDA 呈缓慢波动；经滤波与 per-subject Z-score 后，PPG 脉搏形态清晰、EDA 围绕零均值波动。图 3 的 FFT 谱在约 1.2 Hz（~72 bpm）处出现主峰，VLF/LF/HF 三频带分色标注。图 4 的 STFT 热力图显示心率频率分量的时间稳定性。图 5 的 HRV 箱线图与表 2 给出三状态的生理差异。




图 6 LOSO 聚合混淆矩阵（15 折）




图 7 三分类性能雷达图



图 8 代表性单折（S15）训练曲线

6.1 前端可视化验证系统

为体现研究的落地应用形态，本文构建了一个医学监护仪风格的可交互前端验证系统。系统采用暗色主题，模拟 ICU 监护仪界面。主要功能模块包括：①顶栏支持 15 名被试逐一切换与基线/压力/娱乐三状态段分别查看；②状态卡显示当前查看状态及该被试 LOSO 逐类检出率；③PPG/EDA 双通道波形；④FFT 功率谱与 STFT 时频热力图；⑤聚合混淆矩阵与 HRV 特征分布；⑥代表性折训练曲线与三分类性能指标；⑦H2 融合策略消融柱状图与 Wilcoxon 显著性卡片。

技术栈为 React+TypeScript+Vite+ECharts+Tailwind CSS。后端 Python 流水线将分析结果导出为静态 JSON，前端通过 fetch 读取，实现前后端解耦。该系统采用纯静态预计算架构：每被试的三状态波形/频谱/时频与逐类检出率一次性导出为 JSON，切换瞬时（约 50 ms），无需后端服务，可直接部署至 GitHub Pages。

七、分析与讨论

7.1 整体性能与混淆模式

主模型（特征级融合 dual）在 15 折 LOSO 下取得准确率 $74.9\% \pm 12.5\%$ 、宏 F1 $71.0\% \pm 12.5\%$ 。聚合混淆矩阵（行=真值，列=预测）见表 3。

	预测基线	预测压力	预测娱乐	召回
真基线	2507	186	807	71.6%
真压力	95	1736	134	88.4%
真娱乐	352	70	673	61.5%

表 3 LOSO 聚合混淆矩阵

每类 F1 为：压力 0.877、基线 0.777、娱乐 0.497。压力类识别最佳（召回 88.4%），与其强烈的交感激活一致；娱乐类识别最差，且主要与基线互混（807 个基线样本被误判为娱乐，352 个娱乐样本被误判为基线）。

值得注意的是混淆矩阵的不对称性：基线→娱乐（807）远多于娱乐→基线（352），模型对娱乐呈过度敏感（over-sensitivity）。这与本文采用的类别加权损失有关——娱乐为少数类，被赋予最高权重（频率倒数），模型在惩罚压力下倾向提高娱乐召回，代价是将大量基线样本拉向娱乐。这一代价在宏 F1 指标下被如实反映（娱乐 F1 仅 0.497），也提示未来可探索更精细的代价敏感策略（如焦点损失 focal loss）。整体而言，娱乐与基线的重叠是情感计算领域的普遍观察：娱乐作为“轻度正向唤醒”，其生理特征与静息基线天然接近，是三分类任务的核心难点[4,7]。

7.2 关于 H1 的诚实讨论

本文原假设 H1 设定为“参数量约 2.16 万约束下达到不低于 85%准确率”。实测 74.9%，H1 未获支持。但需强调，严格 LOSO 三分类的 85%是一个过高的预期：业内报告 85%+的工作大多为二分类（压力 vs 非压力）或被试依赖划分（同被试跨窗口）。文献中，即使在被试依赖的宽松设定下，三分类准确率亦多在 80%量级[4]，而娱乐类与基线/压力的混淆是公认的固有难点[4,7]——本文在更严格的 LOSO 下取得 74.9%，处于合理区间。

需特别说明训练曲线的含义：代表性折（S15）的折内验证集（从 14 名训练被试的窗口中随机 8:2 划分）准确率达约 90%，而测试被试仅 75%。这约 15 个百分点的差距主要源于跨被试分布偏移（domain shift）——验证窗口与训练窗口来自相同被试，其分布相近；而测试被试是模型从未见过的个体，其生理基线存在显著差异。该差距并非过拟合，而是生理信号跨被试泛化的固有天花

板。因此本文结论修正为：在严格被试独立评估下，约 2.16 万参数（21,627）的轻量级模型可达到与现有跨被试三分类工作相当的性能水平，验证了浅层架构在资源约束场景下的可行性，而非达到 85%准确率。

7.3 关于 H2：融合策略消融

四种变体的 LOSO 结果见表 4 与图 10。

变体	准确率	宏 F1	参数量	Wilcoxon vs dual
dual（特征级融合）	0.749	0.710	21,627	—
late（晚期融合）	0.680	0.665	16,006	p=0.138（ns）
eda（仅 EDA）	0.668	0.656	3,115	p=0.104（ns）
ppg（仅 PPG）	0.586	0.530	18,771	p=0.001（**）

表 4 H2 消融结果（15 折 LOSO）




图 10 H2 融合策略消融对比

特征级融合在准确率与宏 F1 上均为最优，且相对最弱的 PPG 单模态具有统计显著优势（ $p=0.001$ ，效应量 $r=0.925$ ）。相对 EDA 单模态与晚期融合，融合模型在均值上仍占优（ $\Delta F1$ 分别+0.054、+0.044），但受限于 $n=15$ 的小样本，

未达统计显著。综合而言，H2 获得有条件支持：特征级融合优于单模态，其相对 PPG 的优势显著，相对 EDA/晚期融合的优势呈趋势性。

7.4 EDA 单模态反强于 PPG 的发现

消融显示 EDA-only（宏 F1 0.656）明显优于 PPG-only（0.530）。这表明在跨被试三分类任务中，直接反映交感神经激活的 EDA 比经由 HRV 间接反映自主平衡的 PPG 更具判别力。原因可能在于：HRV 特征个体差异大、对运动伪影敏感，而 EDA 的 SCL 与相位反应对压力/情绪变化更为稳健。

更值得关注的是 EDA-only 的参数效率：仅用 3,115 个参数（不足融合模型的 1/7）即达到 66.8% 的准确率，单位参数所携带的判别信息密度远高于其他变体。这对于极低功耗的嵌入式可穿戴场景（如只能分配数 KB 内存的传感器节点）具有直接工程价值。综合而言，该发现为可穿戴设备传感器选型提供了实证依据——在资源受限、只能选择单一传感器时，EDA 可能是比 PPG 更优的情感状态推断信号。

7.5 局限性与未来工作

本文存在若干局限：其一，15 名被试的样本量限制了统计检验的功效，部分对比未达显著；其二，仅使用手腕信号建模，HRV 分析虽借助 ECG 金标准但模型未直接利用 ECG；其三，娱乐与基线的混淆仍未有效缓解；其四，SQI 权重为启发式设定，未做敏感性搜索。未来可考虑：引入数据增强与域自适应以缩小跨被试差距；使用更长窗口（30–60 s）捕获更丰富的 HRV 动态；探索焦点损失等代价敏感策略；以及将轻量模型实际部署到嵌入式可穿戴平台验证实时性。

八、结论

本文面向可穿戴资源约束场景，设计并实现了一个参数量仅 21,627 的双分支 1D-CNN，联合 PPG 与 EDA 进行三分类情感状态检测，并在 WESAD 数据集上严格采用 LOSO 评估。主要结论为：（1）轻量级浅层架构在严格跨被试评

估下达到 74.9%准确率与 71.0%宏 F1，与现有跨被试三分类工作相当，验证了浅层方法的可行性；（2）特征级融合显著优于 PPG 单模态（ $p=0.001$ ），并在均值上优于 EDA 单模态与晚期融合；（3）EDA 单模态判别力反强于 PPG 单模态，且以仅 3,115 参数达到 66.8%准确率，参数效率最高，为可穿戴传感器选型提供了实证参考；（4）H1 的 85%准确率预期在严格 LOSO 下过高，诚实的负结果与修正讨论本身具有方法学价值。本文同时构建了支持被试与状态切换的可交互前端验证系统，展示了从信号采集到情感状态输出的完整数据流，体现工程化与落地应用思维。

九、参考文献

- [1] Ali M S, Motin M A, Mim M R, et al. A Shallow Deep Learning Model for Stress Monitoring from Photoplethysmography Signals[C]//2025 IEEE International Conference on Computing. IEEE, 2025.
- [2] Nguyen D H L, Le T H, Ngo T D. SPERC: A lightweight and efficient separable CNN for PPG-based emotion recognition[J]. Biomedical Signal Processing and Control, 2026, 92: 106468.
- [3] Cai J, Shi Y, Wang J, et al. A lightweight multi-feature fusion CNN-MLP for wearable stress detection[J]. Scientific Reports, 2024, 14: 22335.
- [4] Schmidt P, Reiss A, Duerichen R, et al. Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection[C]//ICMI 2018: 400-408.
- [5] Ko B, Sim J, Cho C. Physiological Signal Classification with Adaptive Optimization and Transfer Learning for Stress Detection Monitoring[J]. Applied Sciences, 2024, 14(6): 2207.
- [6] Khosravi M H, Roshani S, Karimi A, et al. Photoplethysmography signal quality assessment for heart rate variability analysis using lightweight deep neural networks[J]. Computer Methods and Programs in Biomedicine Update, 2024, 5: 100155.
- [7] Choi H S. Emotion recognition using a Siamese model and a late fusion-based multimodal method in the WESAD dataset with hardware accelerators[J]. Electronics, 2025, 14(4): 723.
- [8] Kim E, Lee S, Lee S. Pulse2stress: HRV-Based Stacked LSTM-AE Framework for PPG Stress Detection[C]//2026 20th International Conference on Sensing Technology. IEEE, 2026.
- [9] Harris C R, Millman K J, van der Walt S J, et al. Array programming with NumPy[J]. Nature, 2020, 585: 357-362.

- [10] Virtanen P, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python[J]. Nature Methods, 2020, 17: 261-272.
- [11] Paszke A, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[C]//NeurIPS 2019.
- [12] Li Q, Clifford G D. Dynamic time warping based machine learning for ECG signal quality assessment[C]//Computers in Cardiology, 2012.

附录：代码说明

代码仓库与完整复现方法详见独立文件《复现方法.md》（已提交）。

关键超参数：窗口 10 s / 步长 5 s；纯净度阈值 0.8；SQI 阈值 0.5；Adam lr=1e-3；批大小 64；最大 60 epoch；patience=10；种子 42。

环境：Python 3.12，NumPy 2.5，SciPy 1.18，PyTorch 2.13（CPU），scikit-learn 1.9。